

Жесткая рецензия на `ls_cp_flcb_theory.ipynb`

28 июня 2026 г.

Файл: `D:\Work_Projects\search_agent\ls_cp_flcb_theory.ipynb`

Объект рецензии: теоретический ноутбук с постановкой алгоритма LS-CP-FLCB (*Lipschitz-Shared Constrained Pareto Functional Lower Confidence Bound*).

Рекомендация: **Reject** / непригодно как теоретическая основа в текущем виде.

Executive summary

Документ выглядит как предварительный концептуальный набросок, а не как доказанная теория алгоритма. Он задает понятную нотацию и содержит несколько элементарных лемм о липшицевости скаляризации, но не доказывает главный заявленный результат: что предложенная стратегия выборки за конечный бюджет восстанавливает ограниченный Парето-фронт с заданной вероятностью и контролируемой ошибкой.

Ключевая теорема об аппроксимации фронта фактически следует из предположения A6, которое уже содержит требуемый результат. Статистическая часть сведена к недоказанному благоприятному событию A4. Ограничения почти не получают самостоятельной обработки, несмотря на слово *Constrained* в названии алгоритма. Заявленная *sample complexity* не является сложностью алгоритма, а лишь локальным достаточным условием при уже удачном распределении запусков.

Оценки

Критерий	Оценка	Комментарий
Novelty	2/5	Идея <i>shared information</i> потенциально интересна, но не отделена от известных подходов.
Rigor	1/5	Главные гарантии постулируются или доказываются через предположения.
Impact	2/5	Возможен исследовательский задел, но текущий текст не является вкладом.
Clarity	3/5	Текст читаемый, но сложные места вынесены в предположения.

1 Центральная теорема об аппроксимации фронта фактически пустая

В разделах 29–31 вводится предположение A6: если для всех направлений сетки найдены ε -оптимальные допустимые точки, то они дают аппроксимацию истинного фронта. Затем Теорема 3 доказывает ровно это же. Это не результат алгоритма, а переформулировка предположения.

Проблема. A6 содержит всю сложность задачи: связь скаляризации Чебышева, сетки направлений, геометрии Парето-фронта и ошибки покрытия. Без явных условий на фронт, достижимость, регулярность, форму множества значений и константы ζ , ψ теорема не несет самостоятельного содержания.

Что нужно исправить. Необходимо заменить A6 на проверяемые геометрические условия и вывести $\zeta(\eta)$ и $\psi(\varepsilon_s)$ явно. Иначе Теорема 3 должна быть честно названа условным наблюдением, а не теоремой аппроксимации Парето-фронта.

Литературный контекст. В multi-objective sequential decision-making известно, что тип скаляризации и форма допустимого множества определяют, какие части Парето-фронта восстанавливаются; см. Roijers et al., JAIR 2013, DOI 10.1613/jair.3987.

2 Алгоритм не доказывает достижение ε -оптимальности по всем направлениям

Теорема 3 начинается с условия

$$s_{\lambda_\ell}(\hat{y}_\ell) \leq \phi_\ell^* + \varepsilon_s$$

для каждого направления. Но в алгоритме нет доказательства, что правило выбора направления и ручки приводит к выполнению этого условия за бюджет T .

Отсутствуют:

- stopping rule;
- sample complexity для покрытия всех направлений;
- связь между T , δ , ε_s , числом направлений L , числом ручек K ;
- доказательство, что активные ячейки не будут преждевременно исчерпаны;
- РАС-гарантия для найденного фронта.

Критический вывод. Основной результат начинается после того, как вся трудная часть уже предполагается выполненной.

Сравнение. Crépon, Garivier, Koolen (2025), *Sequential Learning of the Pareto Front for Multi-objective Bandits*, arXiv 2501.17513, формулируют корректность ответа с вероятностью $1 - \delta$ и обсуждают sample complexity. Здесь аналогичного результата нет.

3 Доверительные интервалы объявлены, но не выведены

В A4 постулируется

$$L_{i,\ell}^{\text{loc}}(t) \leq \phi_{i,\ell}^* \leq U_{i,\ell}^{\text{loc}}(t)$$

для всех i, ℓ, t с вероятностью не меньше $1 - \delta$.

Это центральное статистическое утверждение, но оно не доказано. Более того, не определены:

- шумовая модель для $Y_i(x)$ и $C_i(x)$;
- что именно наблюдается: истинные цели или шумные оценки;
- как обрабатываются ограничения;
- как внутренний оптимизатор возвращает допустимую точку;
- является ли $\hat{\phi}$ несмещенной или состоятельной оценкой;
- как учитывается adaptive sampling;
- почему union bound по всем t корректен;
- почему радиус зависит от $n_{i,\ell}$, если наблюдения заявлены как shared между направлениями.

Критический вывод. A4 — это не техническая деталь, а ядро всей статистической гарантии. В текущем тексте оно заменено декларацией.

Сравнение. Dorn et al. (2025), *Functional multi-armed bandit and the best function identification problems*, arXiv 2503.00509, строят F-LCB через редукцию к оптимизаторам с известной скоростью сходимости. В ноутбуке эта связка заменена предположениями A3–A4.

4 Ограничения почти не анализируются

Название алгоритма содержит **Constrained**, но теория ограничений фактически отсутствует. Допустимость задается как

$$C_i(x) \leq B,$$

но дальше доверительные оценки строятся только для скаляризованной цели ϕ . Нет нижних/верхних доверительных границ для ограничений, нет вероятностной гарантии безопасной допустимости, нет обработки случаев ложной допустимости из-за шума.

Метрика **unsafe pull rate** появляется только в конце как рекомендуемая экспериментальная метрика, но в теории алгоритм никак ее не контролирует.

Критический вывод. Слово *Constrained* в названии алгоритма сейчас в основном декоративное. Чтобы оно было содержательным, нужны отдельные confidence bounds для ограничений и гарантия вида

$$\mathbb{P}\{C_i(x_t) \leq B\} \geq 1 - \delta$$

или контролируемая вероятность нарушения.

5 Правило исключения не связано напрямую с восстановлением Парето-фронта

Теорема 1 говорит: если ячейка (i, ℓ) ε -оптимальна в скаляризованной задаче, она не будет исключена. Но заявленная цель — восстановление Парето-фронта, а не множества ε -оптимальных arm-direction ячеек. Не доказано, что сохранение таких ячеек достаточно для покрытия фронта. Не доказано и обратное: что удаляемые ячейки не содержат точки, нужные для хорошего hypervolume или IGD.

Проблема. Скаляризованная оптимальность по конечной сетке направлений — это суррогат, а не сама целевая гарантия.

Что нужно исправить. Нужно явно связать правило исключения с потерей по IGD/HV или Hausdorff distance между истинным и найденным фронтом.

6 Теорема 2 является почти тавтологией

Теорема 2 вводит ошибки

$$\omega_{i,\ell}(t) = \phi_{i,\ell}^* - L_{i,\ell}^{\text{sh}}(t),$$

$$\omega_{*,\ell}(t) = U_{j^*,\ell}^{\text{sh}}(t) - \phi_\ell^*,$$

и утверждает, что если сумма ошибок меньше зазора, то ячейка исключается.

Это алгебраическое переписывание правила исключения, а не самостоятельный результат. Оно не дает оценки, когда условие выполнится, потому что нет доказанной динамики у $\omega(t)$.

Что нужно. Нужен bound на $\omega(t)$ через число запусков, шум, качество оптимизатора, плотность направлений и adaptive allocation. Сейчас этого нет.

7 Sample complexity в разделе 28 не является sample complexity алгоритма

Следствие в разделе 28 говорит: если есть соседнее направление m , и если там уже накоплено достаточно запусков, то этого достаточно. Но это условное утверждение. Оно не доказывает, что алгоритм выберет это направление, накопит там n , не потратит бюджет на нерелевантные ячейки и сделает это за заявленный T .

Критика. Это не sample complexity алгоритма, а локальное достаточное условие при уже случившемся хорошем распределении сэмплов.

8 Hypervolume bound необоснован

В разделе 33 заявлено

$$HV(P^*) - HV(\hat{P}) \leq DR^{D-1}\eta_{\text{front}}.$$

Для такой оценки нужны аккуратные условия: ориентация минимизации, reference point, включение множеств доминирования, bounded box, отношение между Hausdorff/covering distance и hypervolume difference. В тексте это не доказано.

Более того, покрытие истинного фронта найденными точками в норме ℓ_∞ само по себе не всегда немедленно дает такую простую оценку без дополнительных геометрических условий.

Литературный контекст. Hypervolume как метрика чувствительна к reference point и геометрии множества; см. Zitzler & Thiele 1999 и Daulton et al. 2020, NeurIPS, qEHVI.

9 Недостающая литература

Список литературы слишком короткий и плохо закрывает заявленную область. Нужны как минимум следующие блоки.

Multi-objective sequential decision-making / scalarization

- Roijers D. M., Vamplew P., Whiteson S., Dazeley R. *A Survey of Multi-Objective Sequential Decision-Making*. JAIR, 2013. DOI: 10.1613/jair.3987.
- Hayes C. F. et al. *A practical guide to multi-objective reinforcement learning and planning*. Autonomous Agents and Multi-Agent Systems, 2022. DOI: 10.1007/s10458-022-09552-y.

Sequential Pareto front learning

- Crépon E., Garivier A., Koolen W. M. *Sequential Learning of the Pareto Front for Multi-objective Bandits*. arXiv: 2501.17513, 2025.

Functional / black-box bandits

- Dorn Y., Katrutsa A., Latypov I., Soboleva A. *Functional multi-armed bandit and the best function identification problems*. arXiv: 2503.00509, 2025.
- Kleinberg R., Slivkins A., Upfal E. *Multi-Armed Bandits in Metric Spaces*. arXiv: 0809.4882, 2008.
- Bubeck S., Munos R., Stoltz G., Szepesvári C. *X-armed bandits*. JMLR, 2011.

Bayesian / black-box multi-objective optimization

- Daulton S., Balandat M., Bakshy E. *Differentiable Expected Hypervolume Improvement for Parallel Multi-Objective Bayesian Optimization*. NeurIPS, 2020.
- Daulton S., Eriksson D., Balandat M., Bakshy E. *Multi-Objective Bayesian Optimization over High-Dimensional Search Spaces*. arXiv: 2109.10964, 2021.

GP-UCB / expensive black-box optimization

- Srinivas N., Krause A., Kakade S. M., Seeger M. *Information-Theoretic Regret Bounds for Gaussian Process Optimization in the Bandit Setting*. IEEE Transactions on Information Theory, 2012. DOI: 10.1109/TIT.2011.2182033.

10 Что нужно сделать, чтобы работа стала защищаемой

1. Сформулировать точную статистическую модель: шум целей, шум ограничений, наблюдения, adaptive sampling.
2. Вывести локальные confidence bounds, а не постулировать A4.
3. Дать отдельную теорию для ограничений: feasible classification, safe sampling или probabilistic feasibility.
4. Доказать, что правило выбора направлений и ручек обеспечивает достижение ε_s -оптимальности по всем нужным направлениям за конечный бюджет.
5. Заменить A6 на проверяемые геометрические условия Парето-фронта.
6. Вывести явные $\zeta(\eta)$ и $\psi(\varepsilon_s)$.
7. Доказать связь между ошибками скаляризованных задач и IGD/HV-gap.
8. Провести сравнение с independent-direction baseline, MOBO baseline и sequential Pareto-front learning baseline.
9. Показать ablation: без Lipschitz sharing / с sharing / с разной плотностью сетки направлений.
10. Убрать из текста утверждения уровня «алгоритм вмещаем» и заменить их проверяемыми теоретическими или экспериментальными claims.

Финальная формулировка рецензии

Представленный ноутбук не демонстрирует корректную теорию алгоритма LS-CP-FLCB. Он задает разумную нотацию и несколько элементарных лемм о липшицевости скаляризации, но не доказывает главного: что предложенная стратегия выборки за конечный бюджет восстанавливает ограниченный Парето-фронт с заданной вероятностью и контролируемой ошибкой. Центральная теорема об аппроксимации фронта является следствием предположения A6, которое фактически уже содержит требуемый результат. Статистическая часть сведена к недоказанному благоприятному событию A4, ограничения не получают самостоятельной доверительной обработки, а заявленная sample complexity не является сложностью алгоритма. В текущем виде работа должна рассматриваться как предварительный концептуальный набросок, а не как теоретически обоснованный метод.